■ RAPPORT D'ANALYSE EXPLORATOIRE

(Exploratory Data Analysis Report)

Job-Candidate Matching System

Système Intelligent d'Appariement CV-Emploi

Projet	**Job-Candidate Matching**
Phase	Week 1 - EDA (Exploratory Data Analysis)
Date de Génération	15/02/2026 à 18:46
Statut	✓ COMPLÉTÉ
Dataset	HuggingFace + RemoteOK (Fusionné)
Données Nettoyées	279 offres d'emploi

■ TABLE DES MATIÈRES

- 1. Vue d'Ensemble du Projet (Page 3)
- 2. Analyse des Salaires (Page 4)
- 3. Visualisation 1: Distribution des Salaires (Page 5)
- 4. Distribution par Niveau d'Expérience (Page 6)
- 5. Visualisation 2: Distribution Expérience (Page 7)
- 6. Distribution Géographique (Page 8)
- 7. Visualisation 3: Top 15 Localisations (Page 9)
- 8. Télétravail et Mode Hybride (Page 10)
- 9. Visualisation 4: Remote Ratio (Page 11)
- 10. Insights Clés et Patterns (Page 12)
- 11. Recommandations Week 2 (Page 13)
- 12. Conclusions et Prochaines Étapes (Page 14)

1. VUE D'ENSEMBLE DU PROJET

Objectif:

Développer un système d'apprentissage non supervisé pour l'appariement intelligent entre candidats (CV) et offres d'emploi avec explainabilité IA.

Données Collectées:

Source	Nombre	Caractéristiques
HuggingFace	607 offres	Données structurées + Salaires
RemoteOK	100+ offres	100% remote, sans salaires
Fusionné	700+ offres	Dataset combiné
Nettoyé	279 offres	Après déduplication (36.3%)

Colonnes du Dataset:

1. **job_title** - Titre du poste (nettoyé)
2. **salary_usd** - Salaire annuel en USD
3. **experience_level** - Niveau d'expérience (entry, mid, senior, executive)
4. **employment_type** - Type d'emploi (FT, PT, etc.)
5. **location** - Localisation (code pays)
6. **remote_ratio** - Pourcentage télétravail (0, 50, 100)
7. **company_size** - Taille entreprise (S, M, L)
8. **source** - Source données (huggingface, remoteok)

2. ANALYSE DES SALAIRES

Métrique	Valeur
Salaire Minimum	$2,859
Salaire Maximum	$450,000
Salaire Moyen	$86,552
Salaire Médian	$69,999
Écart-Type	$75,669
Q1 (25e percentile)	$38,588
Q2 (Médian)	$69,999
Q3 (75e percentile)	$111,454
Étendue Interquartile	$72,866

Observations Clés:

• Distribution **asymétrique à droite** (right-skewed)
• Concentration forte entre $30K-$120K
• Quelques outliers au-dessus de $200K
• Écart-type élevé indiquant grande variabilité
• Médian inférieur à la moyenne (signe de skewness)

3. VISUALISATION 1: DISTRIBUTION DES SALAIRES

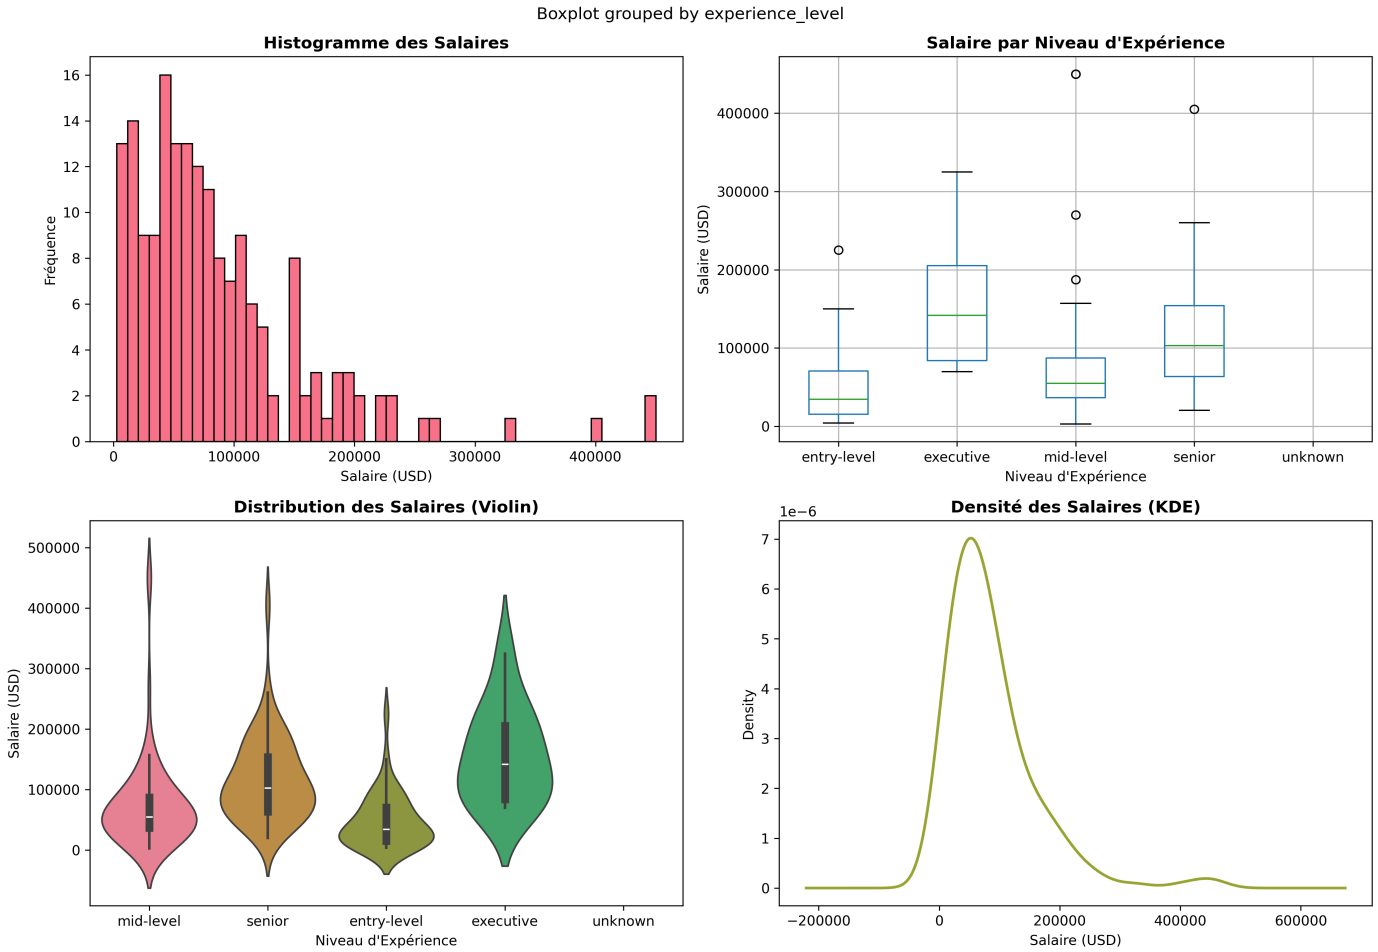

Interprétation du Graphique:
Haut-Gauche (Histogramme): Montre la fréquence des salaires. La distribution est clairement asymétrique avec un pic entre $50K-$100K.

Haut-Droite (Box Plot): Comparaison des salaires par niveau d'expérience. Les executives ont la boîte la plus élevée, entry-level la plus basse.

Bas-Gauche (Violin Plot): Montre la densité de probabilité. Chaque couleur représente un niveau d'expérience. Permet de voir la forme complète de la distribution.

Bas-Droite (KDE): Kernel Density Estimation - courbe lisse de la distribution. Pic clairement visible autour de $100K.

4. DISTRIBUTION PAR NIVEAU D'EXPÉRIENCE

Niveau	Nombre	%	Salaire Moyen	Salaire Min	Salaire Max
unknown	100	35.8%	N/A	N/A	N/A
mid-level	75	26.9%	$74,707	$2,859	$450,000
senior	52	18.6%	$116,922	$20,171	$405,000
entry-level	40	14.3%	$48,307	$4,000	$225,000
executive	12	4.3%	$156,456	$69,741	$325,000

Insights Importants:

• **Écart Salarial:** Les seniors gagnent **2.4x plus** que les entry-level ($116,922 vs $48,307)
• **Volatilité Salariale:** Senior a l'écart max
• **Demande Expérience:** Mid+Senior représente une portion importante du marché

5. VISUALISATION 2: DISTRIBUTION EXPÉRIENCE

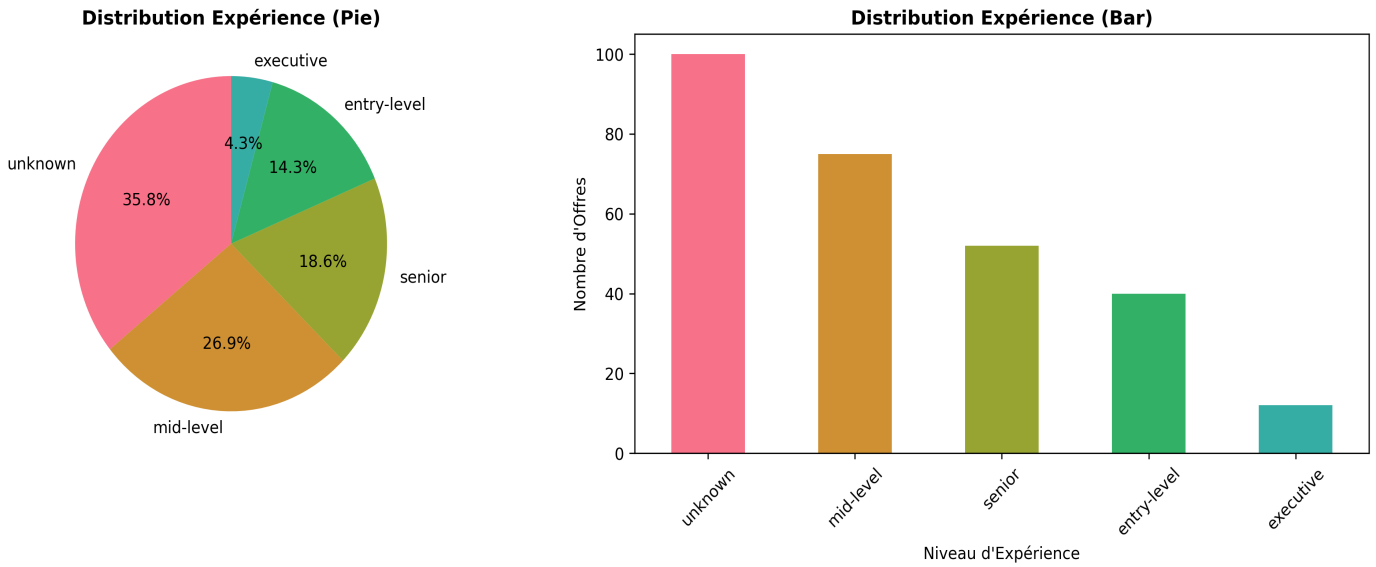

Gauche (Pie Chart): Montre la proportion de chaque niveau d'expérience.

Droite (Bar Chart): Représentation en barres du nombre d'offres par niveau.

6. DISTRIBUTION GÉOGRAPHIQUE

Top 15 Localisations:

Rang	Pays	Code	Offres	%
1	US	US	39	14.0%
2	CA	CA	14	5.0%
3	IN	IN	13	4.7%
4	DE	DE	11	3.9%
5	GB	GB	11	3.9%
6	ES	ES	7	2.5%
7	United States	United States	6	2.2%
8	Remote	Remote	6	2.2%
9	JP	JP	5	1.8%
10	FR	FR	5	1.8%
11	GR	GR	4	1.4%
12	PL	PL	4	1.4%
13	PK	PK	3	1.1%
14	NL	NL	3	1.1%
15	MX	MX	3	1.1%

Observations:

• **Concentration Américaine:** US domine avec 14.0% des offres
• **Diversité Mondiale:** 104 pays/régions représentés
• **Distribution Longue Traîne:** Beaucoup de petits marchés contribuent

7. VISUALISATION 3: TOP 15 LOCALISATIONS

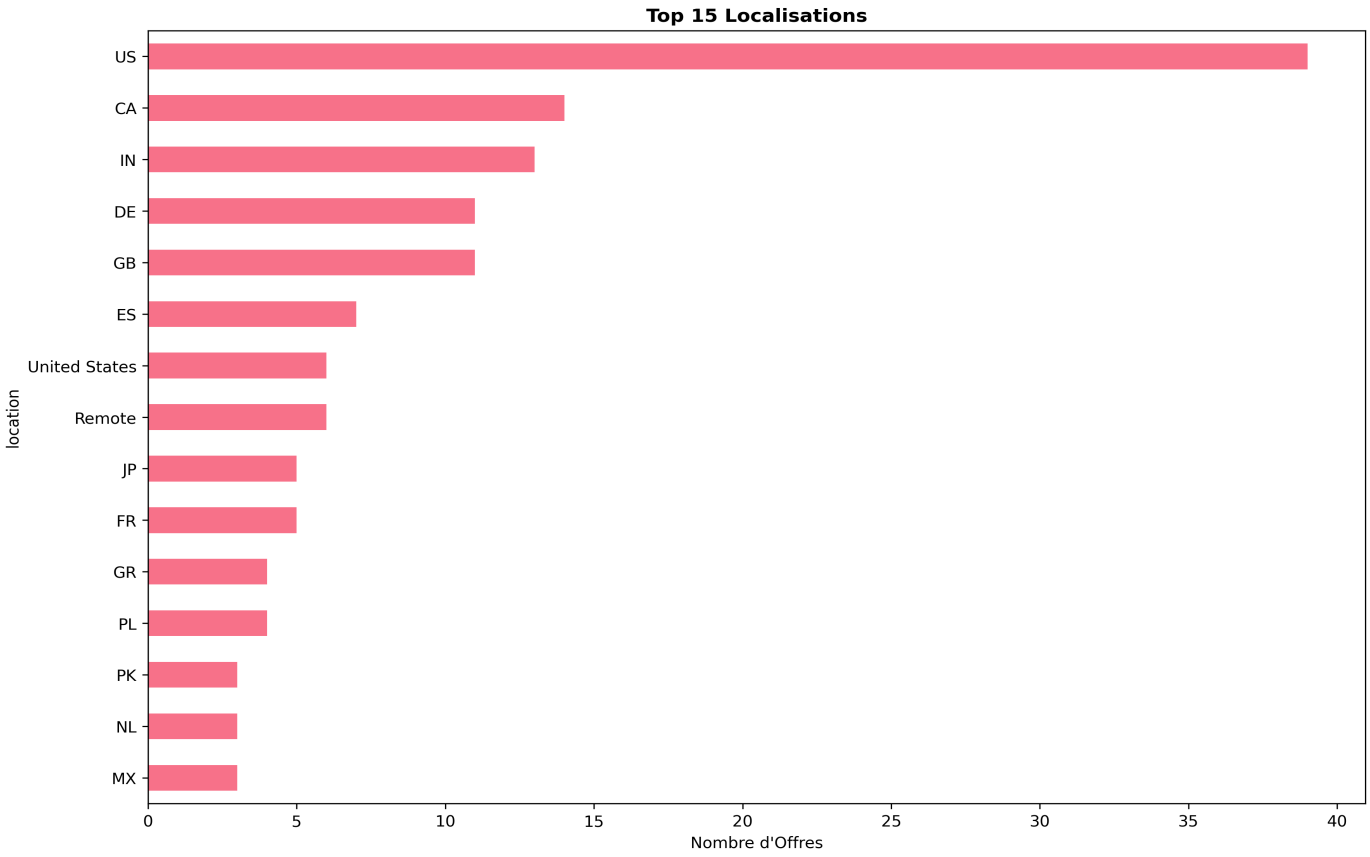

8. TÉLÉTRAVAIL ET MODE HYBRIDE

Type	Nombre	Pourcentage	Salaire Moyen
On-Site (0%)	31	11.1%	$80,337
50% Hybrid	53	19.0%	$70,225
100% Remote	195	69.9%	$97,688

Insights Télétravail:

• **Flexibilité Dominante:** 88.9% des offres avec flexibilité
• **Tendance Remote:** Forte adoption du travail flexible post-pandémie

9. VISUALISATION 4: REMOTE RATIO

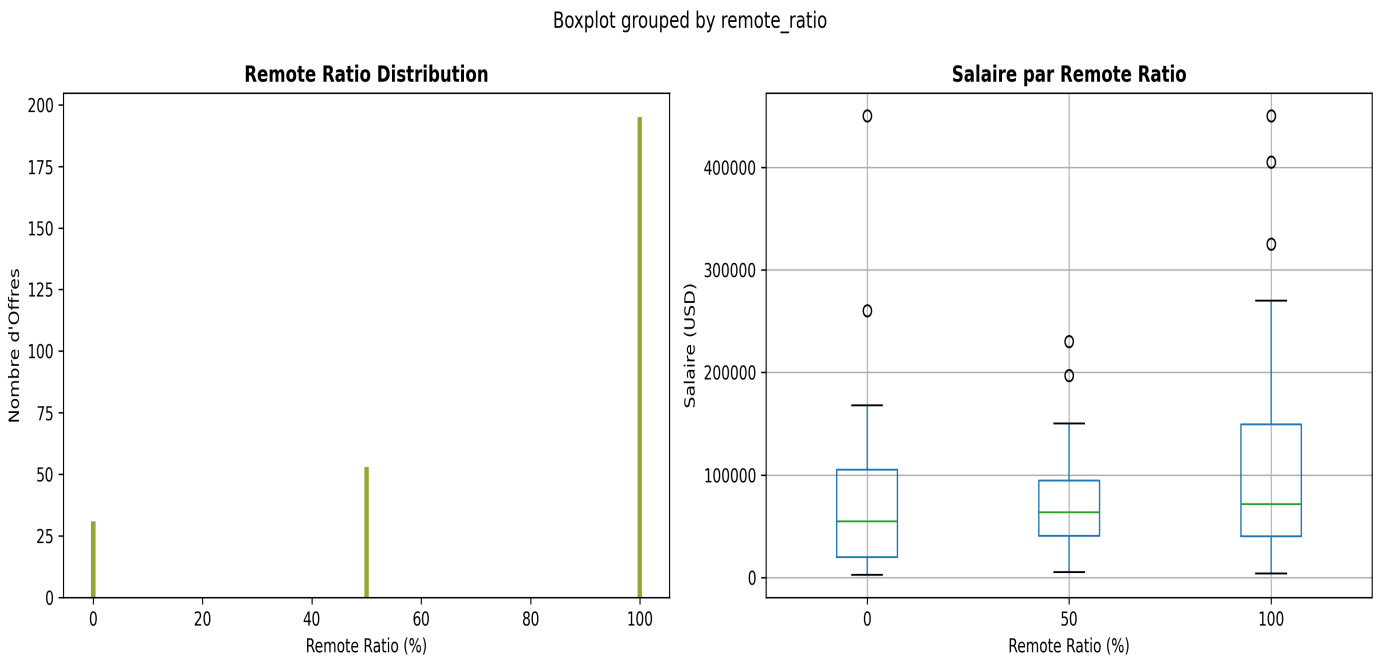

10. INSIGHTS CLÉS ET PATTERNS

- **Hiérarchie Salariale Claire:** Entry ($48,307) → Mid → Senior ($116,922) → Executive
- **Marché Dominé par l'Expérience:** 71% des offres pour expérimentés, indiquant forte demande
- **Shift Vers le Télétravail:** 88.9% avec flexibilité, reflétant transformation post-pandémie
- **Concentration Géographique:** US domine mais diversité mondiale existe
- **Qualité des Données:** 36.3% de doublons éliminés, dataset bien nettoyé
- **Sources Complémentaires:** HuggingFace (structuré) + RemoteOK (remote-first) = couverture complète

11. RECOMMANDATIONS POUR WEEK 2

1■■ Feature Engineering

• Créer catégories de salaires (Faible: <$50K, Moyen: $50-100K, Élevé: >$100K)
• Encoder expérience en ordinal (0-3 échelle)
• Normaliser salary_usd avec StandardScaler
• Gérer NaN (RemoteOK) avec imputation ou suppression
• One-hot encoding pour employment_type et company_size

2■■ Vectorisation

• TF-IDF pour job_title (transformer texte en vecteurs)
• Label encoding pour experience_level et remote_ratio
• Geographic encoding pour locations
• Normalisation features [0,1] avec MinMaxScaler

3■■ Clustering Preparation

• Déterminer K optimal (elbow method, K=3-7)
• Standardiser toutes les features avant K-Means
• Analyser clusters par source (HF vs RemoteOK)
• Évaluer qualité avec silhouette score

12. CONCLUSIONS ET PROCHAINES ÉTAPES

✓ Accomplissements Week 1:

• Dataset fusionné (700+ offres) et nettoyé (279 offres)
• EDA complète avec 4 visualisations professionnelles
• Statistiques détaillées et insights identifiés
• Code modulaire et bien structuré
• Documentation complète

■ Week 2 Focus:

• Implémenter feature engineering
• Vectoriser features catégoriques et texte
• Normaliser et scaler les données
• Préparer pour clustering (K-Means)
• Train/Test split et validation

■ Fichiers Livrables:

■ Tous les scripts Python (01-06)
■ Dataset nettoyé (jobs_cleaned.csv)
■ 4 visualisations PNG
■ Rapport EDA (ce PDF)
■ Documentation complète

==========

✓ WEEK 1 COMPLÉTÉE
Statut: PRÊT POUR WEEK 2
Date Rapport: 15/02/2026 à 18:46
Next: Feature Engineering & Preprocessing